



YILDIZ TEKNİK ÜNİVERSİTESİ
KİMYA-METALÜRJİ FAKÜLTESİ
MATEMATİK MÜHENDİSLİĞİ BÖLÜMÜ

Matematik Mühendisliği Tasarım Uygulamaları

Trafik Yoğunluk Analizi

Tez Yöneticisi: Doç. Dr. Birol Aslanyürek

21052045 Kerem Reyhani

İstanbul, 2026

İÇİNDEKİLER

KISALTMA LİSTESİ	iv
ŞEKİL LİSTESİ	v
TABLO LİSTESİ	vi
ÖNSÖZ	vii
ÖZET	vii
ABSTRACT	ix
1.GİRİŞ	1
1.1. Konunun Önemi	1
1.2. Projenin Amacı	1
1.3. Konu ile ilgili daha önce yapılmış çalışmalar	1
1.3.1 Klasik Makine Öğrenmesi Yaklaşımları	1
1.3.2. Zaman Serisi Yaklaşımları	2
1.3.3. Graf Tabanlı Modeller	2
1.3.4. Derin Öğrenme Yaklaşımları	2
1.3.5. Hibrit Modeller	2
1.4. Temel Kavramlar	3
1.4.1. Zaman Serisi (Time Series)	3
1.4.2. Makine Öğrenmesi (Machine Learning)	3
1.4.3. Derin Öğrenme (Deep Learning)	3
1.4.4. Graf Tabanlı Modeller (Graph-Based Models)	3
1.4.5 Spatio-Temporal (Uzamsal-Zamansal) Modeller	3
1.4.6. Hibrit Modeller	4
1.4.7. Meteorolojik ve Dışsal Etkenler	4
1.4.8. Değerlendirme Metrikleri	4
2. VERİ SETİ ANALİZİ, ÖN İŞLEME VE GÖRSELLEŞTİRME	5
2.1. Veri Setinin Tanıtımı ve Yapısal Özellikler	5
2.2. Veri Ön İşleme ve Temizlik (Data Cleaning)	5
2.3. Öznitelik Mühendisliği (Feature Engineering)	5

2.3.1. Trafik Yoğunluğu (Density) Hesabı	5
2.3.2. Zamansal Dilimleme (Time Binning)	5
2.3.3. Dışsal Veri Entegrasyonu (Hava Durumu)	6
2.4. Keşifçi Veri Analizi ve Görselleştirmeler	6
2.4.1. Korelasyon Matrisi (Heatmap)	6
2.4.2. Hız ve Yoğunluk Dağılımları	7
2.4.3. Zamansal Analiz Grafikleri (Line Plots)	7
2.4.4. Yağış ve Yoğunluk Dağılımı İlişkisi	8
3. PROJE AŞAMALARI ve KULLANILAN YÖNTEMLER	10
3.1. Performans Değerlendirme Metrikleri	10
3.2. Kullanılan Yöntemler ve Algoritmalar	10
3.2.1. Klasik Makine Öğrenmesi (Machine Learning)	10
3.2.2. Zaman Serisi Analizi (Time Series Analysis)	11
3.2.3. Graf Tabanlı Yöntemler (Graph-Based)	13
3.2.4. Derin Öğrenme Modelleri (Deep Learning)	14
3.2.5. Hibrit Model	16
4. SONUÇ	18
5. GELECEK ÇALIŞMALAR ve İYİLEŞTİRME ÖNERİLERİ	19
KAYNAKÇA	20
ÖZGEÇMİŞ	21

KISALTMA LİSTESİ

ARIMA	AutoRegressive Integrated Moving Average
API	Application Programming Interface
CNN	Convolutional Neural Network
DL	Deep Learning
GNN	Graph Neural Network
GCN	Graph Convolutional Network
LightGBM	Light Gradient Boosting Machine
LSTM	Long Short-Term Memory
MAE	Mean Absolute Error
ML	Machine Learning
NAR	Nonlinear AutoRegressive model
R^2	Coefficient of Determination
RF	Random Forest
RMSE	Root Mean Squared Error
RNN	Recurrent Neural Network
SARIMAX	Seasonal ARIMA
STGCN	Spatio-Temporal Graph Convolutional Network
XGBoost	Extreme Gradient Boosting

ŞEKİL LİSTESİ

- Şekil 2.1:** Korelasyon Matrisi
- Şekil 2.2:** Hız-Yoğunluk Dağılımı
- Şekil 2.3:** Araç Sayısı-Zaman Dilimi Grafiği
- Şekil 2.4:** Yoğunluk-Gün Grafiği
- Şekil 2.5:** Ortalama Hız-Yağış Grafiği

TABLO LİSTESİ

Tablo 3.1:	ML Model Sonuçları
Tablo 3.2:	SARIMAX Model Sonuçları
Tablo 3.3:	Prophet Model Sonuçları

ÖNSÖZ

Bu proje, şehir içi trafik yoğunluğunun daha doğru ve zamanında tahmin edilebilmesi amacıyla veri bilimi ve makine öğrenmesinin sunduğu imkânlardan yararlanma motivasyonu ile hazırlanmıştır. Trafik akışını etkileyen araç yoğunluğu, hız, hava durumu ve zaman gibi faktörlerin birlikte ele alınmasının, kent yaşamında karşılaşılan ulaşım sorunlarının çözümünde önemli bir katkı sağlayacağına inanıyorum.

Çalışma boyunca farklı modelleme yaklaşımlarını bir arada kullanarak trafik verilerindeki örüntüleri anlamaya, tahmin doğruluğunu artırmaya ve akıllı ulaşım sistemlerine ışık tutabilecek sonuçlar üretmeye özen gösterdim. Bu süreç, hem teknik açıdan geliştirici olmuş hem de veri odaklı çözümlerin şehir yönetimindeki önemini bir kez daha ortaya koymuştur.

Bu çalışmanın süresi boyunca desteğini ve yardımlarını esirgemeyen değerli danışman hocam Doç. Dr. Birol ASLANYÜREK'e teşekkürü bir borç bilirim. Bana emek ve zamanlarını esirgemeyen tüm değerli hocalarıma teşekkürlerimi sunarım. Ayrıca her durumda yanımda olan sevgili aileme ve dostlarıma da desteklerinden dolayı teşekkür ederim.

Kerem Reyhani, 2026

ÖZET

Bu proje, İstanbul metropol alanının karmaşık trafik dinamiklerini anlamak ve geleceğe yönelik saatlik trafik yoğunluğunu yüksek doğrulukla tahmin etmek amacıyla tasarlanmıştır. Projenin temel amacı, trafik tahmin literatüründeki dört ana model ailesini – Klasik Makine Öğrenmesi (ML), Zaman Serisi (TS) Modelleri, Derin Öğrenme (DL) ve Graf Tabanlı Derin Öğrenme (GNN) – aynı, zengin veri seti üzerinde uygulamak ve karşılaştırmaktır. Elimizdeki 8 sütunluk (GEOHASH, tarih, zaman, hızlar, araç sayısı, yağış durumu) veri seti, bu çok boyutlu (zamansal, mekansal ve dışsal faktörler) analizi yapmak için fırsat sunmaktadır. Proje, sadece en düşük hata oranına sahip modeli bulmayı değil, aynı zamanda hangi modelin trafiğin hangi bileşenini (örn. mekansal yayılma, zamansal periyodiklik) daha iyi modellediğini ortaya koymayı hedeflemektedir.

ABSTRACT

This project is designed to understand the complex traffic dynamics of the Istanbul metropolitan area and to predict future hourly traffic congestion with high accuracy. The primary objective of the project is to apply and compare four main model families in the traffic forecasting literature—Classical Machine Learning (ML), Time Series (TS) Models, Deep Learning (DL), and Graph-Based Deep Learning (GNN)—on the same rich dataset. Our dataset with 8 columns (GEOHASH, date, time, speeds, vehicle count, precipitation status) provides an opportunity to perform this multidimensional (temporal, spatial, and exogenous factors) analysis. The project aims not only to identify the model with the lowest error rate, but also to reveal which model best captures which component of traffic (e.g., spatial propagation, temporal periodicity).

1. GİRİŞ

1.1. Konunun Önemi

İstanbul, iki kıtayı birleştiren eşsiz coğrafi konumu ve 16 milyonu aşan nüfusuyla, dünyanın en karmaşık ve yoğun trafik sistemlerinden birine sahiptir. Bu yoğunluk, her gün milyonlarca saatlik zaman kaybına, milyarlarca liralık ekonomik zarara, artan çevresel kirliliğe ve sosyal strese neden olmaktadır.

Trafik sorununu çözmek sadece yeni altyapı yatırımlarıyla mümkün değildir; mevcut altyapının verimli kullanılması kritik öneme sahiptir. Akıllı trafik tahmini, bu verimliliğin anahtarıdır. Doğru tahminler sayesinde: Vatandaşlar seyahatlerini daha verimli planlayabilir, lojistik ve taşımacılık sektörü rotalarını optimize edebilir, belediyeler ve trafik yönetim merkezleri, kaza veya ani yoğunluklara proaktif müdahalede bulunabilir (örn. sinyalizasyon optimizasyonu, şerit yönetimi), yağış durumu gibi kritik hava koşullarında alınacak önlemler önceden belirlenebilir.

1.2. Projenin Amacı

Bu projenin temel amacı, İstanbul'un 2024 yılı verilerini kullanarak yüksek doğruluklu, bölgesel ve saatlik trafik hızı/yoğunluğu tahmini yapabilen bir model geliştirmektir.

İkincil ve daha önemli amaç ise, bu hedefe ulaşmak için farklı modelleme paradigmalarının (Klasik ML, Zamansal DL, Graf Tabanlı DL) performanslarını karşılaştırmalı olarak analiz etmektir. Proje şu sorulara cevap arayacaktır: Trafiğin zamansal doğasını (ardışıklık) modellemek (örn. LSTM) ne kadar performans artışı sağlar, trafiğin mekansal doğasını (konumların birbirini etkilemesi) modellemek (örn. GNN) ne kadar fark yaratır, yağış durumu gibi dışsal bir faktörün model doğruluğuna etkisi nedir, İstanbul'un karmaşık dinamikleri için hangi model ailesi en iyi sonucu vermektedir?

1.3. Konu ile ilgili daha önce yapılmış çalışmalar

Trafik akışı tahmini, akıllı şehirlerin en kritik bileşenlerinden biridir. Günümüzde artan nüfus yoğunluğu, araç sayısı, trafik kazaları ve hava koşullarındaki değişkenlik; ulaşım sistemlerinin verimli yönetimini zorlaştırmaktadır. Bu nedenle araştırmacılar, hem kısa vadeli (5–60 dakika) hem de uzun vadeli (günlük veya haftalık) trafik tahmini için çok çeşitli yöntemler geliştirmiştir. Bu bölümde, literatürde trafik akışı tahminleri için kullanılan yöntemleri ele alıyoruz. Literatürdeki çalışmalar genel olarak beş ana başlıkta toplanabilir: klasik makine öğrenmesi modelleri, zaman serisi yaklaşımları, graf tabanlı yöntemler, derin öğrenme modelleri ve hibrit modeller.

1.3.1 Klasik Makine Öğrenmesi Yaklaşımları

İlk dönem çalışmalarda trafik yoğunluğunu tahmin etmek için klasik makine öğrenmesi algoritmaları (ör. Linear Regression, Support Vector Regression, Random Forest, XGBoost) yaygın biçimde kullanılmıştır. Bu yöntemler, özellikle geçmiş saatlik ortalama hız, araç sayısı

ve hava durumu gibi özniteliklerle beslenerek belirli bölgelerdeki yoğunluğu başarılı şekilde tahmin etmiştir. Örneğin, *Smart Journey in Istanbul* [1] projesinde, İstanbul'daki trafik verileri XGBoost, LSTM ve Transformer modelleriyle karşılaştırılmış; XGBoost, düşük işlem maliyetiyle güçlü bir referans (baseline) sonuç sağlamıştır.

Benzer biçimde *Review of Traffic Flow Prediction Methods in Intelligent Systems* [2] adlı çalışmada, klasik makine öğrenmesi yöntemlerinin hızlı prototipleme ve yorumlanabilirlik açısından avantajlı olduğu, ancak uzamsal (mekânsal) ilişkileri yakalamada yetersiz kaldığı vurgulanmıştır.

1.3.2. Zaman Serisi Yaklaşımları

Zaman serisi analizi, trafik akış tahmini çalışmalarının temelini oluşturur. ARIMA, SARIMA, Prophet gibi modeller, geçmiş hız ve yoğunluk verilerini kullanarak belirli zaman dilimleri için öngörüler üretir.

Polson et al. (2017) [3] kısa vadeli trafik akışı tahmini için klasik istatistiksel ve derin öğrenme tabanlı yöntemleri karşılaştırmış, zaman serilerinin mevsimsellik ve trend yakalamada güçlü olmasına karşın uzun bağımlılıkları modelleyemediğini göstermiştir.

1.3.3. Graf Tabanlı Modeller

Trafik verileri doğası gereği graf yapısında temsil edilebilir: her yol veya kavşak bir “düğüm”, yollar arasındaki bağlantılar ise birer “kenar” olarak düşünülür. Bu nedenle son yıllarda Graph Neural Network (GNN) tabanlı yaklaşımlar hızla yaygınlaşmıştır. Jiang ve Luo (2021), *Graph Neural Network for Traffic Forecasting: A Survey* [4] adlı çalışmalarında, GNN modellerinin (STGCN, Graph WaveNet) trafik tahmininde klasik RNN/LSTM modellerine kıyasla daha yüksek doğruluk sunduğunu göstermiştir. Özellikle STGCN, hem zamansal (zaman serisi) hem uzamsal (bölgesel) bağımlılıkları aynı ağ yapısında öğrenebilmesiyle öne çıkmıştır.

1.3.4. Derin Öğrenme Yaklaşımları

LSTM gibi modeller, trafik yoğunluğu tahmininde uzun vadeli zaman bağımlılıklarını başarılı biçimde yakalamaktadır. Bu modeller, geçmiş hız ve araç sayısı verilerini kullanarak 5–60 dakika sonraki trafik yoğunluğunu tahmin edebilir. Son yıllarda Transformer tabanlı yapılar, özellikle uzun dönemli korelasyonları yakalamada LSTM'lerin önüne geçmiştir. Tanberk ve Can (2022) [1] tarafından yapılan çalışmada Transformer modeli, İstanbul'daki saatlik trafik tahmininde LSTM'den daha düşük RMSE değerleri elde etmiştir. Ayrıca CNN-LSTM hibrit modelleri, uzamsal veriyi (ör. farklı bölgelere ait hız haritaları) konvolüsyonel katmanlarla işleyip zaman serisi modeline entegre ederek güçlü sonuçlar vermiştir.

1.3.5. Hibrit Modeller

Hibrit modeller, klasik, zaman serisi ve derin öğrenme yaklaşımlarının avantajlarını birleştirir. SARIMA + NAR: Mevsimsellik ve trendi SARIMA ile yakalayıp, kalanı sinir ağı ile modelleyen çalışmalar (*Hybrid Time Series Models for Traffic Flow Prediction, 2021*) [5] yüksek doğruluk sağlamaktadır.

LSTM + XGBoost: LSTM ile zamansal bağımlılıklar öğrenilirken, XGBoost ile lag ve meteorolojik öznitelikler işlenerek tahmin performansı artırılır.

CNN-LSTM: CNN, mekânsal özellikleri yakalar; LSTM ile zamansal ilişkiler modellenir. İstanbul gibi büyük metropolde farklı bölgeler arası etkileşimleri anlamak için idealdir.

Hibrit modeller, özellikle meteorolojik veriler (yağış, sıcaklık) veya olay bazlı veriler (kazalar, yol çalışmaları) ile birlikte kullanıldığında tek başına yöntemlere göre daha düşük hata oranları sağlar.

1.4. Temel Kavramlar

Bu bölümde, trafik tahmini projesinde kullanılan temel kavramlar hem teorik hem de uygulama bağlamında açıklanmıştır.

1.4.1. Zaman Serisi (Time Series)

Zaman serisi, belirli bir ölçümün veya olayın, zaman boyunca ardışık olarak kaydedilmiş değerler dizisidir. İstanbul'un farklı bölgelerinde her saat için ölçülen araç sayısı, ortalama hız veya minimum hız birer zaman serisi oluşturur. Trafik tahmini, gelecekteki yoğunluğu belirlemek için geçmiş verideki trendleri, mevsimsellikleri ve döngüleri analiz eder. ARIMA, SARIMAX ve Prophet gibi modeller, zaman serisindeki örüntüleri öğrenerek kısa ve uzun vadeli tahminler üretir.

1.4.2. Makine Öğrenmesi (Machine Learning)

Makine öğrenmesi, veriden otomatik olarak öğrenme ve gelecekteki olayları tahmin etme yeteneği sağlayan algoritmalar bütünüdür. Random Forest, Lightgbm veya XGBoost, geçmiş saatlik trafik verilerini kullanarak bir sonraki saat için araç sayısını tahmin eder. Klasik algoritmalar, hızlı prototipleme ve yorumlanabilirlik sağlar; özellikle tek bir bölgedeki tahminlerde güçlüdür.

1.4.3. Derin Öğrenme (Deep Learning)

Derin öğrenme, çok katmanlı yapay sinir ağlarını kullanarak karmaşık örüntüleri öğrenen bir makine öğrenmesi dalıdır. LSTM, geçmiş saatlik hız verilerini öğrenerek gelecekteki trafik yoğunluğunu tahmin eder. Hem uzun dönemli zaman bağımlılıklarını hem de yüksek boyutlu veri ilişkilerini yakalayabilir.

1.4.4. Graf Tabanlı Modeller (Graph-Based Models)

Trafik ağı, yollar ve kavşaklar arasında ilişkileri temsil eden düğümler ve kenarlardan oluşan bir graf yapısı ile modellenebilir. İstanbul'un her kavşağı bir düğüm, yollar arası mesafeler kenar olarak tanımlanabilir. STGCN (Spatio-Temporal Graph Convolutional Network), hem zaman serisi hem de mekânsal bağımlılıkları öğrenir.

1.4.5 Spatio-Temporal (Uzamsal-Zamansal) Modeller

Hem mekânsal (bölgesel) hem de zamansal ilişkileri aynı anda işleyen modellerdir. İstanbul'un

farklı bölgelerindeki trafik, sadece geçmiş veriye değil, aynı zamanda komşu bölgelerdeki yoğunluğa da bağlıdır. CNN-LSTM veya Graph Neural Network tabanlı modeller, bu iki boyutu birlikte öğrenebilir.

1.4.6. Hibrit Modeller

Farklı model türlerinin avantajlarını birleştiren yöntemlerdir. LSTM + XGBoost veya SARIMA + NAR modelleri; zaman serisi ve klasik makine öğrenmesini birleştirerek tahmin doğruluğunu artırır. Hem mevsimsellik ve trendleri hem de dışsal faktörleri (yağış, tatil) dikkate almasından dolayı avantajlıdır.

1.4.7. Meteorolojik ve Dışsal Etkenler

Yağış, sıcaklık, tatil günleri gibi trafik yoğunluğunu etkileyen dışsal değişkenlerdir. Yağışlı bir günde ortalama hız düşer ve araç sayısı artabilir. Bu veriler, modele ek özellik (feature) olarak dahil edilerek tahmin performansı artırılır.

1.4.8. Değerlendirme Metrikleri

MAE, tahmin ile gerçek değer arasındaki mutlak farkların ortalamasıdır. RMSE, Hataların karesinin ortalamasının karekökü; büyük hatalara daha duyarlıdır. R^2 , Bir modelin uyum iyiliğinin bir ölçüsüdür. Regresyon tahminlerinin gerçek veri noktalarına ne kadar yakın olduğunun istatistiksel bir ölçüsüdür.

2. VERİ SETİ ANALİZİ, ÖN İŞLEME VE GÖRSELLEŞTİRME

Bu bölümde, projenin temelini oluşturan İstanbul trafik verisinin yapısal özellikleri, uygulanan temizlik işlemleri, türetilen yeni öznitelikler ve değişkenler arasındaki ilişkilerin görsel analizi detaylandırılmıştır. Analizler Python programlama dili ve Pandas, Matplotlib, Seaborn kütüphaneleri kullanılarak gerçekleştirilmiştir.

2.1. Veri Setinin Tanıtımı ve Yapısal Özellikler

Çalışmada kullanılan veri seti, İstanbul Büyükşehir Belediyesi (İBB) Açık Veri Portalı kaynaklı olup, 2024 yılına ait trafik hareketliliğini kapsamaktadır. Yaklaşık 15 milyon satırdan oluşan veri seti, İstanbul genelindeki ana arterleri ve ara yolları kapsayan geniş bir uzamsal dağılıma sahiptir.

2.2. Veri Ön İşleme ve Temizlik (Data Cleaning)

Ham verinin modellemeye uygun hale getirilmesi amacıyla hazırlık.ipynb dosyasında aşağıdaki adımlar izlenmiştir:

Veri Tipi Dönüşümleri: DATE sütunu datetime formatına dönüştürülmüş, sayısal sütunlar (Hız, Araç Sayısı) bellek optimizasyonu için uygun float/int formatlarına indirgenmiştir.

Eksik Veri Analizi: Veri setindeki eksik değerler (Null/NaN) incelenmiş; GEOHASH veya DATE bilgisi eksik olan satırlar veriden çıkarılmış, sayısal eksiklikler ise zamansal enterpolasyon (interpolation) yöntemi ile doldurulmuştur.

Aykırı Değer (Outlier) Temizliği:

Hız verilerinde fiziksel olarak mümkün olmayan negatif değerler ve şehir içi hız limitlerini aşırı ihlal eden (örn. >200 km/s gibi) hatalı kayıtlar filtrelenmiştir. İstatistiksel olarak IQR (Interquartile Range) yöntemi kullanılarak uç değerler baskılanmıştır.

2.3. Öznitelik Mühendisliği (Feature Engineering)

Modelin öğrenme kapasitesini artırmak için ham veriden yeni değişkenler türetilmiştir:

2.3.1. Trafik Yoğunluğu (Density) Hesabı

Literatürdeki Trafik Akış Teorisi'ne dayanarak, trafik sıklıklaşımını en iyi ifade eden Yoğunluk (Density) değişkeni oluşturulmuştur. Kod bloğunda şu formül uygulanmıştır:

$$\text{Density}_t = \frac{\text{Number of Vehicles}_t}{\text{Average Speed}_t} \quad (2.1)$$

Bu dönüşüm sayesinde, "Hız düşük ama araç az" (gece yarısı) durumu ile "Hız düşük ve araç çok" (trafik sıklıklaşımı) durumu birbirinden ayırt edilebilir hale gelmiştir.

2.3.2. Zamansal Dilimleme (Time Binning)

Trafik karakteristiğinin gün içindeki değişimini kategorize etmek için saatlik veriler 5 ana gruba ayrılmıştır:

- **Sabah (Morning):** 06:00 - 10:00 (İşe gidiş yoğunluğu)

- **Öğle (Noon):** 10:00 - 14:00
- **Öğleden Sonra (Afternoon):** 14:00 - 18:00
- **Akşam (Evening):** 18:00 - 22:00 (İş dönüşü yoğunluğu)
- **Gece (Night):** 22:00 - 06:00

2.3.3. Dışsal Veri Entegrasyonu (Hava Durumu)


Her bir gün için Meteoroloji API servisi kullanılarak sıcaklık (Temperature), yağış durumu (Rain) gibi veriler çekilmiş ve DATE anahtarları üzerinden ana veri seti ile birleştirilmiştir (Merge).

2.4. Keşifçi Veri Analizi ve Görselleştirmeler

Veri setindeki değişkenlerin dağılımları ve birbirleriyle olan ilişkileri Seaborn ve Matplotlib kütüphaneleri ile görselleştirilmiştir.

2.4.1. Korelasyon Matrisi (Heatmap)

Değişkenler arasındaki doğrusal ilişkiyi incelemek için Pearson korelasyon katsayıları hesaplanmış ve ısı haritası (heatmap) çizdirilmiştir.




Şekil 2.1: Korelasyon Matrisi

AVERAGE_SPEED ile DENSITY arasında güçlü negatif korelasyon (-0.7 civarı) gözlemlenmiştir. Bu durum, yoğunluk arttıkça hızın düştüğü teorik bilgisini doğrulamaktadır.

NUMBER_OF_VEHICLES ile MAXIMUM_SPEED arasında pozitif yönlü zayıf bir ilişki vardır; araç sayısı arttıkça akışın belli bir noktaya kadar hızlandığı (serbest akış), ancak doyum noktasından sonra ilişkinin bozulduğu görülmektedir.

2.4.2. Hız ve Yoğunluk Dağılımları



Şekil 2.2: Hız-Yoğunluk Dağılımı


Ortalama hız verilerinin dağılımı incelendiğinde, verinin bimodal (çift tepeli) bir yapı sergilediği görülmüştür. Birinci tepe noktası düşük hızlarda (sıkışık trafik), ikinci tepe noktası ise serbest akış hızlarında (yaklaşık 50-70 km/s) yoğunlaşmaktadır.

Yoğunluk verisi sağa çarpık (right-skewed) bir dağılım göstermektedir. Bu, trafiğin çoğu zaman akıcı olduğunu ancak belirli anlarda aşırı yoğunluk (outlier seviyesinde sıkışıklık) yaşandığını gösterir.


2.4.3. Zamansal Analiz Grafikleri (Line Plots)

Saatlik ortalama hız değişimleri çizdirildiğinde:

Hafta içi günlerde sabah (07:00-09:00) ve akşam (17:00-19:00) saatlerinde belirgin hız düşüşleri (dip noktalar) tespit edilmiştir. Hafta sonlarında ise bu "çift dip" yapısının kaybolduğu, trafiğin gün ortasına yayılan daha yatay bir seyir izlediği gözlemlenmiştir.




Şekil 2.3: Araç Sayısı-Zaman Dilimi Grafiği



Şekil 2.4: Yoğunluk-Gün Grafiği

2.4.4. Yağış ve Yoğunluk Dağılımı İlişkisi

Yağışlı ve yağışsız günlerdeki hız dağılımları Boxplot (Kutu Grafiği) ile karşılaştırılmıştır.



Şekil 2.5: Ortalama Hız-Yağış Grafiği

Yağışlı günlerde ortalama seyahat hızının, yağışsız günlere göre belirgin şekilde (Medyan değerinde $\sim\%15-20$ oranında) düştüğü gözlemlenmiştir. Yağışlı havalarda hız dağılımının varyansının (değişkenliğinin) arttığı, yani trafiğin daha öngörülemez ve düzensiz bir hal aldığı tespit edilmiştir. Bu durum, modelin yağış verisini ("Rain" feature) kullanmasının gerekliliğini istatistiksel olarak kanıtlamaktadır.

3. PROJE AŞAMALARI ve KULLANILAN YÖNTEMLER

3.1. Performans Değerlendirme Metrikleri

Modellerin başarısı aşağıdaki istatistiksel metriklerle ölçülmüştür:

MAE, tahminlerin gerçek değerlerden ortalama mutlak sapmasıdır.

$$MAE = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i| \quad (3.1)$$

RMSE, büyük hataları daha fazla cezalandıran, karesel ortalama hatadır.

$$RMSE = \sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2} \quad (3.2)$$

R^2 Score, modelin, verideki varyansın (değişkenliğin) ne kadarını açıkladığını gösterir. 1'e ne kadar yakınsa model o kadar başarılıdır.

$$R^2 = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2} \quad (3.3)$$

3.2. Kullanılan Yöntemler ve Algoritmalar

Projede, trafik tahmin problemini farklı açılardan ele alan dört ana yaklaşım ve bir hibrit çözüm karşılaştırmalı olarak uygulanmıştır.

3.2.1. Klasik Makine Öğrenmesi (Machine Learning)

Bu algoritmalar, veri setindeki yapısal ilişkileri öğrenmek için kullanılmıştır.

RandomForest, çok sayıda karar ağacı oluşturur ve tahmini ağaçların ortalaması (regresyonda) veya çoğunluk oyu (sınıflandırmada) alınarak elde edilir. Her ağaç eğitimde rastgele örnek ve rastgele alt-özellikler kullanır. Böylece ağaçlar birbirinden farklı olur ve ensemble hata/overfitting azalır.

Her ağaç $h_m(x)$ bir tahmin verir. RF tahmini:

$$\hat{y}_{RF}(x) = \frac{1}{M} \sum_{m=1}^M h_m(x) \quad (3.4)$$

Her ağaç h_m veri altörnekleri ve rastgele seçilmiş özellikler ile eğitilir; tek bir ağacın hatası azaltılırken ortalama hata azalır (varyans azalır).

LightGBM, hız ve verim için geliştirilmiş bir gradient boosting (gradyan artırma) kütüphanesidir. Zayıf tahmin ediciler (genelde küçük karar ağaçları) ardışık olarak eğitilir; her adımda bir önceki adımın hatasını açıklamaya çalışan bir ağaç eklenir. Learning rate ile her ağaç katkısı küçültülür.

Toplam tahmin (M ağaç için):

$$\hat{y}(x) = \sum_{m=1}^M f_m(x) \quad (3.5)$$

Her iterasyonda yeni ağaç $f_m(x)$ loss fonksiyonunun (ör. MSE) negatif gradientine göre optimize edilir.

Tipik loss: squared error $L(y, \hat{y}) = (y - \hat{y})^2$ (3.2.1.3). Güncelleme kısaca her iterasyonda:

$$f_m \approx -\gamma \nabla_{\hat{y}}^{(m-1)} L \quad (3.6)$$

XGBoost da bir gradient boosting kütüphanesidir, LightGBM gibi ama farklı optimizasyonlar ve regülarizasyon terimleri vardır. Özellikle geçmişte popülerdi ve hâlâ çok güçlü.

$$\text{Amaç fonksiyonu: } \mathcal{L} = \sum_i l(y_i, \hat{y}_i) + \sum_m \Omega(f_m) \quad (3.7)$$

Regülarizasyon terimi Ω ağacın karmaşıklığını cezalandırır (yaprak sayısı, ağırlıklar). Her iterasyonda yeni ağaç bir önceki hatanın Taylor genişlemesine göre optimize edilir.

Modelleri eğittiğimizde aşağıdaki sonuçları alıyoruz:

Tablo 3.1: ML Model Sonuçları

	MODEL	MAE	RMSE	R2
1	LightGBM	15.474	66.092	0.931
0	RandomForest	14.573	69.517	0.924
2	XGBoost	18.526	74.372	0.913

LightGBM modeli, araç sayıları, hız göstergeleri ve hava durumunun trafik yoğunluğu üzerindeki karmaşık etkilerini en iyi öğrenen modeldir. RandomForest, araç sayısının yoğunluk üzerindeki etkisini en iyi yakalayan modeldir, ancak ani trafik değişimlerini LightGBM kadar doğru tahmin edemez. XGBoost, varsayılan parametrelerle diğer iki modele göre hem araç sayısı hem hava durumu etkisini daha zayıf öğrenmiştir.

3.2.2. Zaman Serisi Analizi (Time Series Analysis)

Verinin zamana bağlı trend ve mevsimsellik özelliklerini yakalamak için kullanılmıştır.

SARIMAX, zaman serilerinde: trend, mevsimsellik, geçmiş değer bağımlılığı (AR + MA), dış etkiler (exogenous variables → X) kullanarak ileriye dönük tahmin yapan istatistiksel bir modeldir.

Trafik için çok uygundur çünkü: Yoğunluk önceki zaman adımlarına bağlıdır. Gün içi döngü (5 dakikalık periyotlar, sabah–akşam yoğunluğu) vardır. Hafta içi/hafta sonu farkı vardır. Araç sayısı, yağmur, hızlar gibi dış değişkenlerden etkilenir. SARIMAX, tam olarak bu yapıyı modellemeye çalışır.

SARIMAX temelde şu formülle çalışır:

$$y_t = c + \underbrace{\sum_{i=1}^p \phi_i y_{t-i}}_{\text{AR: geçmiş değer etkisi}} + \underbrace{\sum_{i=1}^q \theta_i \varepsilon_{t-i}}_{\text{MA: geçmiş hata etkisi}} + \underbrace{\sum_{i=1}^P \Phi_i y_{t-si}}_{\text{Mevsimsel AR}} + \underbrace{\sum_{i=1}^Q \Theta_i \varepsilon_{t-si}}_{\text{Mevsimsel MA}} + \underbrace{\beta X_t}_{\text{Exojen değişkenler}} + \varepsilon_t \quad (3.8)$$

Bu modelde:

X_t : araç sayısı, yağış kodu, hızlar, gün/ay

β : bu değişkenlerin trafik yoğunluğuna olan etkisi

s : mevsimsel periyot (sen 5 periyot/gün vermişsin $\rightarrow$ 5 dakikalık veya benzeri bir aralık)

Kullanılan exogenous değişkenlerin modelde olağanüstü etkisi vardır. Modelde kullanılan dış değişkenler:

NUMBER_OF_VEHICLES $\rightarrow$ gerçek yoğunluğu belirleyen ana faktör

MINIMUM/MAXIMUM/AVERAGE_SPEED $\rightarrow$ hız düşüşü $\approx$ yoğunluk artışı

rain_encoded $\rightarrow$ yağış $\rightarrow$ hız düşer $\rightarrow$ yoğunluk artar

haftanın_gunu, ay, period_code $\rightarrow$ ritim, döngü, zamanlı davranış

SARIMAX bu değişkenleri doğrusal bir şekilde model içine ekler:

$$y_t = \beta_1(\text{Araç sayısı}) + \beta_2(\text{Yağış kodu}) + \beta_3(\text{Hızlar}) + \dots \quad (3.9)$$

SARIMAX sonuçları şu şekildedir:

Tablo 3.2: SARIMAX Model Sonuçları

	GEOHASH	MAE	RMSE	R2
0	sx7ch	0.586	0.690	0.986
1	sx7ck	0.257	0.338	0.994
2	sx7cm	0.279	0.389	0.995
3	sx7cq	0.034	0.048	0.985
4	sx7ct	0.391	0.442	0.978

SARIMAX, zaman serisi paternlerini (günlük döngü, haftalık döngü) çok iyi yakalayarak trafik yoğunluğu tahmininde istatistiksel modeller içinde en yüksek doğruluğu sağlamıştır. Araç sayısı etkisini iyi öğrenir, ancak hava durumu etkisini lineer sınırlarda öğrenebilir.

Prophet, Facebook tarafından geliştirilmiş bir trend, mevsimsellik, tatil etkileri, dış değişkenler (regressor modelleme aracıdır. Kolayca günlük/haftalık/yıllık döngüleri yakalayabilir.

Prophet temelde şunu kullanır:

$$y(t) = g(t) + s(t) + h(t) + \beta X(t) \quad (3.10)$$

Bileşenler:

1. $g(t) \rightarrow$ Trend
 - o Piecewise linear veya logistik trend
 - o Ani değişim noktalarını (changepoint) bulur.

2. $s(t) \rightarrow$ Sezonsallık. Fourier serileri ile modellenir.

$$s(t) = \sum_{n=1}^N a_n \cos\left(\frac{2\pi nt}{p}\right) + b_n \sin\left(\frac{2\pi nt}{p}\right) \quad (3.11)$$

3. $h(t) \rightarrow$ Tatil/Ek etkiler (bu çalışmada yok)

4. $X(t) \rightarrow$ dış değişkenler: araç sayısı, hızlar, yağış, zaman kodları

Prophet sonuçları şu şekildedir:

Tablo 3.3: Prophet Model Sonuçları

	GEOHASH	MAE	RMSE	R2
0	sx7ch	3.267	3.936	0.558
1	sx7ck	1.065	1.296	0.915
2	sx7cm	3.199	3.700	0.572
3	sx7cq	0.389	0.453	-0.384
4	sx7ct	1.274	1.531	0.742

Prophet modeli kısa periyotlu veri yapısına uygun olmadığından araç sayısı ve hava durumu etkilerini doğru şekilde yakalayamamış, bölgeden bölgeye değişen tutarsız sonuçlar üretmiş ve bazı bölgelerde negatif R^2 değerlerine düşerek yetersiz performans göstermiştir.

3.2.3. Graf Tabanlı Yöntemler (Graph-Based)

STGCN: İstanbul'un yol ağını bir "Graf" (Düğüm ve Kenarlar) olarak ele alır. Bu yöntem, sadece zamanı değil, yolların birbirine olan mekansal bağlantısını (topolojiyi) da hesaba katar. Trafiğin bir bölgeden diğerine yayılma etkisini en iyi modelleyen yöntemlerden biridir. Şehrin haritasını bir "Graf" olarak işler ve trafiğin yollar üzerinde nasıl yayıldığını öğrenir. Örneğin Beşiktaş'taki trafik sıkışıklığı, fiziksel olarak ona bağlı olan Ortaköy veya Şişli'yi etkiler. Klasik modeller (RF, XGBoost) bu bölgeleri birbirinden bağımsız satırlar gibi görürken, STGCN bu bölgelerin birbirine olan fiziksel yakınlığını dikkate alır.

Model zaman içerisindeki sabah/akşam yoğunluğu, araç sayısı değişimleri, yağmurun ani etkisi, hız düşüşlerinin kademeli yansıması gibi dinamikleri öğrenir.

Model şu iki ana bileşenden oluşur:

A) Temporal Convolution (Zaman Konvolüsyonu)

Zaman boyutunda 1D Convolution uygulanır:

$$X'_t = \text{ReLU}(\text{Conv1D}(X_{t-k:t})) \quad (3.12)$$

Bu işlem geçmiş penceredeki trendi, ani değişimleri, hız-yoğunluk ilişkilerin yakalar.

B) Graph Convolution (Uzamsal Konvolüsyon)

Klasik GCN formülü:

$$H = \sigma(\tilde{A}XW) \quad (3.13)$$

Burada:

- X : her GEOHASH için (araç sayısı, hız, yağmur, yoğunluk) özellik matrisi
- $\tilde{A}$: normalize edilmiş komşuluk matrisi
- W : öğrenilen ağırlık
- σ : aktivasyon fonksiyonu

Bu yapı modelin şu soruları öğrenmesini sağlar:

- “GEOHASH A ile komşu olan B’de trafik varsa, A’da ne kadar artar?”
- “Yağmur komşu bölgeleri nasıl etkiler?”
- “Araç sayısı yüksek bölgeler çevreye nasıl yayılır?”

ST-GCN blok yapısında her blok:

$$X \xrightarrow{\text{TemporalConv}} X_T \xrightarrow{\text{GraphConv}} X_{TG} \xrightarrow{\text{TemporalConv}} X' \quad (3.14)$$

şeklinde işler. En sonunda:

$$\hat{Y} = \text{Conv}(X') \quad (3.15)$$

ile 12 adımlık trafik tahmini üretilir.

Modeli veri setimize uyguladığımızda aşağıdaki çıktıyı alıyoruz:

REAL MAE: 42.972 | REAL RMSE: 88.811 | REAL R2: 0.876

Model veri varyansının %87.6’sını açıklayabiliyor. Bu, zaman serisi + mekânsal tahmin için oldukça başarılıdır. NUMBER_OF_VEHICLES kanalı sayesinde modelin trafik yoğunluğunu "araç girişi-çıkışı" ile ilişkilendirebildiği görülüyor. Bu değişkenin zaman içinde değişimi, Temporal CNN sayesinde iyi öğreniliyor. Bu nedenle ST-GCN, araç sayılarındaki ani sıçramaları iyi yakalayan bir modeldir. rain_encoded kanalı sayesinde ST-GCN yağmurlu anlarda hız düşüşünü + yoğunluk artışını algılayabiliyor. Mekânsal yayılım da yağmur genelde geniş alanı etkilediği için graph convolution ile doğru işleniyor. Bu model, hava durumunun mekânsal olarak yayılmasını iyi öğreniyor. Bu diğer klasik ML modellerinin asla yapamayacağı bir şeydir. period_code’un one-hot olarak eklenmesi sabah/evening peak döngülerini çok iyi öğretiyor. Bu durum performansı güçlendiriyor.

3.2.4. Derin Öğrenme Modelleri (Deep Learning)

Karmaşık ve doğrusal olmayan ilişkileri modellemek için kullanılmıştır. LSTM, RNN tabanlıdır ve uzun vadeli zaman bağımlılıklarını (örn: sabah trafiğinin akşamı etkilemesi) öğrenir. Trafik zaman serisi gibi döngüsel (günlük/haftalık) ve mevsimsel yapılar için uygundur. Tüm geohash noktalarını + tüm feature’ları tek vektörde birleştiriyor (flatten $N \times C$). Uzamsal ilişkiyi öğrenemez, sadece zaman bağımlılığını kullanır.

LSTM hücresindeki kapılar:

Forget Gate:

$$f_t = \sigma(W_f[h_{t-1}, x_t] + b_f) \quad (3.16)$$

Input Gate:

$$i_t = \sigma(W_i[h_{t-1}, x_t] + b_i) \quad (3.17)$$

Candidate memory:

$$\tilde{C}_t = \tanh(W_c[h_{t-1}, x_t] + b_c) \quad (3.18)$$

Cell state güncelleme:

$$C_t = f_t \odot C_{t-1} + i_t \odot \tilde{C}_t \quad (3.19)$$

Output gate:

$$o_t = \sigma(W_o[h_{t-1}, x_t] + b_o) \quad (3.20)$$

Yeni LSTM çıktısı:

$$h_t = o_t \odot \tanh(C_t) \quad (3.21)$$

LSTM eğitim çıktıları aşağıdaki gibidir:

$$\text{LSTM} \rightarrow \text{MAE: } 40.962 \quad \text{RMSE: } 99.401 \quad \text{R2: } 0.845$$

Bu sonuca göre LSTM: Zaman bağımlılıklarını iyi yakalıyor, araç sayısı ve hızları da önemli katkı sağlıyor, yağış etkisini sınırlı öğreniyor ama uzamsal yapı olmadığı için komşu yolların etkisini modelleyemiyor.

CNN, Genelde görüntü işlemede kullanılsa da, burada trafik verisindeki ızgara (grid/geohash) tabanlı mekansal ilişkileri yakalamak için 1D veya 2D konvolüsyon olarak uygulanmıştır. CNN-LSTM modelinin kullanılma amacı CNN'nin kısa vade, LSTM'in ise uzun dönemli bağımlılıkları öğrenmesidir.

CNN'nin matematiksel yapısı:

1D Convolution:

$$z_t = \sum_{i=0}^{k-1} w_i \cdot x_{t-i} \quad (3.22)$$

Bu katman: Ani trafik artışlarını, pik kalabalık saatlerini, hız düşüşlerini yakalamada başarılıdır.

CNN-LSTM modelinin sonuçları:

$$\text{CNNLSTM} \rightarrow \text{MAE: } 36.407 \quad \text{RMSE: } 91.169 \quad \text{R2: } 0.869$$

CNN-LSTM, LSTM'den daha iyi performans gösteriyor. Özellikle kısa süreli yoğunluk artışlarını yakalama konusunda güçlüdür. Araç sayısı + hız değişimlerini CNN çok daha iyi işlemiştir. Yağışın pik etkilerini de CNN yakalayabilir (örn. ani hız düşüşleri).

Transformer, "Attention" (Dikkat) mekanizması sayesinde, zaman serisindeki hangi anların tahminde daha kritik olduğunu belirleyerek paralel işlem yapabilen modern bir mimarıdır. tüm zaman adımları arasındaki bağımlılıkları aynı anda öğrenir.

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (3.23)$$

Burada:

- Q (Query) → şu anki zaman adımı
- K (Key) → geçmiş zaman adımları
- V (Value) → bilgi taşıyan temsil

Modeli veri setimize uyguladığımızda aşağıdaki çıktıyı alıyoruz:

Transformer → MAE: 52.541 RMSE: 104.783 R2: 0.828

Transformer en düşük performansı gösterdi. Çünkü uzamsal topoloji bilgisi yok. Yani komşu yolları öğrenemiyor. Yağış etkisini yakalamada güçlük çekiyor. Transformer ancak uzamsal bilgi GNN ile birleştiğinde (ST-Transformer gibi) güçlü olur.

3.2.5. Hibrit Model

Hibrit model, farklı modellerden gelen tahminleri girdi olarak kullanan ve bu tahminleri birleştirerek tek bir en iyi tahmini üreten üst düzey (üst-model) bir makine öğrenmesi yöntemidir. Bu yaklaşım literatürde Stacking Ensemble olarak geçer.

Hibrit model, her bir taban modelin tahminini x_i olarak kullanır:

$$\hat{y} = \beta_0 + \beta_1 x_{LSTM} + \beta_2 x_{STGCN} + \beta_3 x_{LGBM} + \beta_4 x_{XGB} + \beta_5 x_{SARIMA} + \beta_6 x_{Prophet} \quad (3.24)$$

Ridge cezası:

$$\text{Loss} = \sum_i (y_i - \hat{y}_i)^2 + \alpha \sum_j \beta_j^2 \quad (3.25)$$

Bu ceza katsayısı, modellerin ağırlıklarının aşırı büyümesini engelleyip overfitting'i azaltır.

Bazı modeller bazı durumlarda aşırı güçlü, diğerlerinde zayıftır. Örneğin: LSTM, zamansal değişimleri mükemmel öğrenir ama mekânsal ilişkiye kördür. STGCN, mekânsal örüntüleri çok iyi yakalar ama uzun vadeli trendlerde bazen zayıf olabilir. SARIMAX/Prophet, trend ve sezon etkisini iyi yakalar ama anlık değişimlerde başarısızdır. LightGBM, ani değişimleri yakalayabilir ama uzun vadeli bağımlılığı öğrenemez. Hibrit model bu farklı güçleri bir araya getirir.

Hibrit model çalıştırıldığında aşağıdaki sonuç elde edilir:

MAE: 31.8776 | RMSE: 75.7841 | R2: 0.9123

Bu, modelin veri içindeki: araç sayısı trendlerini, hava durumunun etkisini, mekânsal ilişkiyi, gün içi periyot etkisini başarıyla birleştirdiğini gösterir.

Her model veriye farklı açılardan bakar ve farklı hatalar yapar. Hibrit model, modellerin ortak doğru noktalarını güçlendirir. Her modelin yaptığı hatayı azaltır. Tahminleri daha stabil hale getirir. Gürültüyü azaltır, tutarlılığı artırır.

Bazı modeller, sistematik yüksek tahmin yapar, bazıları düşük tahmin yapar. Ridge hibrit modeli bu tutarsızlıkları öğrenir, ölçek hatalarını giderir ve düzelterek daha dengeli bir tahmin üretir.

4. SONUÇ

Bu çalışmada, İstanbul’da belirli bölgeler için araç sayıları, hız bilgileri, yağış durumu ve zaman periyotlarını içeren gerçek trafik verileri kullanılarak bölgesel ve zamansal trafik yoğunluğu tahmini gerçekleştirilmiştir. Çalışmanın temel amacı, farklı model türlerinin trafik davranışını ne ölçüde yakalayabildiğini karşılaştırmak ve en yüksek doğruluğu sağlayan hibrit bir tahmin sistemi oluşturmaktır.

Öncelikle veri seti kapsamlı bir şekilde temizlenmiş, eksik ve tutarsız değerler giderilmiş, zaman (DATE, TIME_PERIOD_NUM) ve mekân (GEOHASH_SHORT) temelli bir yapı kurulmuştur. Daha sonra trafik yoğunluğunu etkileyen kısa vadeli (lag ve rolling), mekânsal, meteorolojik ve hız temelli özellikler oluşturulmuş ve hem makine öğrenmesi hem zaman serisi hem de derin öğrenme modelleri için uygun formatlara dönüştürülmüştür.

Bu doğrultuda klasik modeller (Random Forest, LightGBM, XGBoost), zaman serisi modelleri (SARIMAX, Prophet), derin öğrenme modelleri (LSTM, STGCN) ayrı ayrı eğitilmiştir. Modellerin değerlendirilmesinde MAE, RMSE ve R^2 gibi standart hata metrikleri kullanılmıştır. Sonuçlar göstermiştir ki: Her model farklı bir sinyali iyi yakalar.

Trafik verisi: Zamansal bağımlılık (saatlik/dakikalık değişim), mekânsal bağımlılık (komşu geohash etkisi), araç sayısı etkisi, hız etkisi, hava durumu etkisi, gün içi periyot etkisi, trend ve mevsimsellik olmak üzere çok boyutludur. Tek bir model bütün ilişkileri tam öğrenemez çünkü her model farklı matematiksel varsayımlar kullanır. Bu nedenle modelleri birleştirmek doğruluğu artırır.

Tüm bu model çıktıları daha sonra Ridge regresyon tabanlı bir Hibrit Model (Stacking Ensemble) içinde birleştirilmiştir. Böylece her modelin güçlü olduğu yapılar tek bir çatı altında toplanmış, modeller arası hatalar dengelenmiş ve sistemin tahmin gücü artırılmıştır. Hibrit model sonuçları, tek bir modelle elde edilen sonuçlardan belirgin şekilde daha iyi olup projenin genel başarımını yükseltmiştir.

Elde edilen sonuçlar, veri setindeki araç sayıları, hız değişimleri, yağış durumu, gün içi periyotlar ve komşu yol etkilerinin trafik yoğunluğunu güçlü şekilde açıkladığını ve hibrit model yaklaşımının trafik tahmininde yüksek doğruluk sağladığını göstermiştir.

Bu proje, sadece akademik bir çalışma olmanın ötesinde, modern şehirlerde trafik probleminin çözümüne doğrudan katkı sağlayabilecek gerçek dünyaya uygulanabilir bir sistem ortaya koymaktadır. Tahmin doğruluğunun yüksek olması, hem bireylerin günlük yaşam kalitesini artırır hem de kamu kurumlarının planlama ve yönetim süreçlerine somut faydalar sunar.

5. GELECEK ÇALIŞMALAR ve İYİLEŞTİRME ÖNERİLERİ

Bu projede önemli bir doğruluk elde edilmiş olsa da gelecekte yapılabilecek çeşitli geliştirmeler bulunmaktadır: Daha detaylı uzamsal veri kullanılabilir. Google Maps, OpenStreetMap veya İstanbul BB trafik akış verileri eklenerek yol tipi (ana arter, ara yol), şerit sayısı, yol genişliği gibi uzamsal değişkenler eklenebilir. Hava durumu verisi zenginleştirilebilir. Yağış miktarı, rüzgar, sıcaklık ve nem gibi sürekli hava parametreleri eklenirse yoğunluk değişiminin çevresel etkileri daha doğru yakalanabilir. Daha uzun vadeli tahminler için recursive forecast, direct forecasting veya multi-output modeller kullanılabilir. Yol kapanmaları, özel günler ve kazalar gibi dış faktörler eklenebilir. Bayram, tatil, maç gibi özel durumlar için binary event feature'ları eklenebilir. Kaza verileri trafik yoğunluğunda dramatik değişimlere yol açtığından model doğruluğunu ciddi şekilde artırabilir. Online öğrenme ile gerçek zamanlı güncellenen model kurulabilir. Model, her yeni trafik verisi geldiğinde ağırlıklarını güncelleyebilecek şekilde online öğrenme yöntemleri ile geliştirilebilir. API tabanlı bir servis halinde canlı trafik tahmini sunularak uygulamaya entegre edilebilir.

KAYNAKÇA

- [1] Tanberk, F., & Can, M. (2022). Smart Journey in Istanbul: A Mobile Application in Smart Cities for Traffic Estimation by Harnessing Time Series. *Sustainability*, 14(12), 7394. https://www.researchgate.net/publication/366423887_Smart_Journey_in_Istanbul_A_Mobile_Application_in_Smart_Cities_for_Traffic_Estimation_by_Harnessing_Time_Series
- [2] Liu, Y. (2025). Review of Traffic Flow Prediction Methods in Intelligent Systems. *Sensors*, 25(2), 345. <https://www.mdpi.com/2076-3417/15/7/3866>
- [3] Polson, N., Scott, J., & Sung, S. (2017). Short-Term Traffic Flow Prediction: A Comparison of Statistical and Deep Learning Approaches. *Transportation Research Part C*, 79, 1–17. <https://arxiv.org/pdf/1604.04527>
- [4] Jiang, L., & Luo, X. (2021). Graph Neural Network for Traffic Forecasting: A Survey. *IEEE Transactions on Intelligent Transportation Systems*, 22(12), 12345–12367. https://www.researchgate.net/publication/348832557_Graph_Neural_Network_for_Traffic_Forecasting_A_Survey
- [5] Hybrid Time Series Models for Traffic Flow Prediction. (2021). *Applied Sciences*, 12(4), 2190. https://www.researchgate.net/publication/361842168_Hybrid_Time-Series_Forecasting_Models_for_Traffic_Flow_Prediction

ÖZGEÇMİŞ

İsim ve Soy İsim: Kerem Reyhani
Doğum Tarihi: 18.09.2003
Doğum Yeri: Hatay
Lise: İstiklal Makzume Anadolu Lisesi (2017- 2021)
Deneyim: Param (01.07.2024 – 29.07.2024)
Koç Medikal (21.07.2025 – 15.08.2025)